

PPG 기반 사용자 인증 연구 설계 보고서

Cross-Session 변동성에 강인한 PPG Verification Representation Learning

구현 및 실험 수행을 위한 방법론 구체화 보고서

연구 대상 문제 | 공개 Multi-Session PPG 기반 Cross-Session 사용자 검증

제안 모델명 | SIM-PPG: Session-Invariant Morphology-Preserving PPG Verification Network

선정 주 데이터셋 | SigD (PhysioNet 기반 재구성 경로 확인 필요)

즉시 실행 가능한 파일럿 데이터셋 | Seeing Red

작성일: 2026년 5월 22일

본 문서는 논문 초본 작성 이전의 구현·실험 계획안이며, 실험 결과를 주장하지 않는다.

문서 구성

1. 연구 의사결정 요약
2. 연구 범위와 문제 정의
3. 관련 문헌 분석 및 방법론으로의 연결
4. 후보 데이터셋 비교와 선정 전략
5. 제안 방법론: SIM-PPG
6. 데이터 전처리 및 학습 샘플 구성
7. 학습 및 평가 프로토콜
8. 실험 설계와 비교 실험 목록
9. 평가 지표 및 결과 보고 양식
10. 연구의 차별성 및 노벨티
11. 실제 구현 로드맵
12. 리스크, 한계 및 대안 전략
13. 향후 논문 초본으로의 전환 구조

참고문헌

부록 A. 알고리즘 의사코드

부록 B. 실험 수행 체크리스트

문서의 핵심 원칙

직접 데이터를 수집하지 않고 공개 또는 재현 가능한 공개 경로의 PPG 데이터만 사용한다. 여러 문제를 병렬로 해결하려 하지 않고, cross-session verification 안정성이라는 하나의 문제를 중심으로 방법론·평가·노벨티를 정렬한다.

1. 연구 의사결정 요약

본 보고서의 결론은 PPG 기반 인증의 실용적 장애 요인 중 하나인 세션 간 변동성(cross-session variability)을 단일 핵심 문제로 확정하고, 검증(verification) 태스크에서 이를 직접 줄이는 표현 학습 모델을 설계하는 것이다. 시간 간격 자체가 항상 성능을 단조롭게 악화시킨다고 가정하지 않으며, 서로 다른 세션에서 발생하는 신호 분포 이동을 인증 embedding 이 얼마나 흡수할 수 있는지를 검증한다.

항목	최종 결정
연구 문제	동일 사용자라도 세션이 달라질 때 PPG embedding 분포가 이동하여 genuine score 가 낮아지는 문제
태스크	User verification (1:1 matching). Identification accuracy 는 보조 분석으로만 사용
제안 방법	SIM-PPG: cross-session identity contrastive learning + session centroid alignment + morphology preservation + SQL weighting
선정 주 데이터셋	SigD: 232 명, 2 회 이상 세션, 세션 간격 3 시간-3000 일. MIMIC-III/PhysioNet 기반 재구성 경로를 사용
파일럿/외부 검증	Seeing Red: 15 명, 사용자당 6-11 세션, 스마트폰 카메라 PPG. 직접 다운로드 가능
주 지표	EER, TAR@FAR=1%, ROC-AUC, FAR, FRR, cross-session 성능 저하량 (Delta EER)
가장 중요한 평가 원칙	subject-disjoint split, session-disjoint enrollment/probe, threshold validation-only 고정, window overlap leakage 금지

본 연구의 범위: 여러 문제의 병렬 해결이 아니라 하나의 배포 핵심 문제를 깊게 해결




그림 1. 연구 범위의 집중화: cross-session verification 안정성이라는 단일 문제를 중심으로 설계한다.

구현 착수 전에 확인할 사항

SigD 는 논문 및 공개 GitHub 코드에서 MIMIC-III waveform 과 임상 정보로 재구성하는 경로가 제시되어 있다. 다만 MIMIC-III 관련 자료는 PhysioNet 자격 승인 및 데이터 사용 약정이 필요할 수 있으므로, 접근 승인 절차와 실제 추출 가능한 대상 수 · 세션 수를 먼저 확인한다. 승인이 지연되면 Seeing Red 로 전체 파이프라인을 먼저 구현한다.

2. 연구 범위와 문제 정의

2.1 연구가 해결할 단 하나의 문제

PPG 신호는 심혈관계와 말초 혈류 특성에 의해 사용자별 구분 정보를 담지만, 같은 사용자라도 서로 다른 측정 세션에서는 생리 상태, 접촉 조건, 장비 환경, 노이즈 및 시간 경과가 복합적으로 달라질 수 있다. 이로 인해 등록(enrollment) 시점에서 생성한 템플릿과 후속 인증(probe) 시점의 신호가 서로 멀어져 false rejection 이 증가한다. PPG 인증 survey 와 cross-session 연구들은 이 문제를 실제 배포를 가로막는 핵심 문제로 반복적으로 제시한다 [1-6, 11].

최종 문제 정의

공개 multi-session PPG 데이터만을 사용하여, 서로 다른 세션에서 취득된 동일 사용자의 신호는 가까운 embedding 으로 정렬하고 다른 사용자의 신호는 충분히 분리하는 session-invariant, identity-discriminative verification representation 을 학습한다.

2.2 이번 연구에서 의도적으로 다루지 않는 문제

- rPPG spoofing 공격 방어는 보안 확장 주제이며, 본 연구의 1 차 목표에는 포함하지 않는다.
- 활동 상태, 스트레스, 감정 상태를 명시적으로 입력으로 사용하는 context-aware authentication 은 추후 확장으로 둔다.
- 초저전력 온디바이스 배포와 전력 측정은 핵심 성능 문제가 아니라 후속 시스템 평가 항목으로 둔다.
- 인구통계학적 공정성 개선 알고리즘은 개발하지 않지만, SigD 메타데이터가 허용하는 경우 subgroup 결과는 보고한다.

2.3 연구 질문과 검증 가설

ID	연구 질문 / 가설	판정 근거
RQ1 / H1	일반 encoder 는 within-session 보다 cross-session 에서 EER 이 증가하는가?	Baseline 의 Delta EER > 0 및 신뢰구간
RQ2 / H2	Cross-session positive sampling 과 session alignment 가 일반 contrastive fine-tuning 보다 안정적인가?	제안법의 cross-session EER 감소 및 TAR@FAR 증가
RQ3 / H3	Morphology 보존 loss 가 과도한 정렬로 인한 사용자 분리력 저하를 완화하는가?	Ablation, genuine/impostor margin, UMAP
RQ4 / H4	품질 기반 weighting 이 저품질 세션을 제거하지 않고도 안정성을 개선하는가?	Quality-stratified EER 와 데이터 유지율
RQ5	시간 간격이 길수록 항상 성능이 감소하는가, 혹은 변동성만 증가하는가?	Interval-binned EER/분산 분석; 단조 감소를 전제하지 않음

3. 관련 문헌 분석 및 방법론으로의 연결

3.1 인증 분야의 핵심 공백

PPG 인증 survey 는 PPG 가 획득이 쉽고 생체 활성 정보를 포함하는 반면, 인증 연구가 아직 체계화 단계에 있으며 실제 조건과 보안 평가가 부족하다고 정리한다 [1]. 최근 security-focused review 는 특히 데이터셋 표준화 부족, FAR/FRR/EER 중심 평가의 불일치, 공격 및 현실 조건 검증 부족을 비판하며 분류 정확도 중심 접근에서 security-first authentication 접근으로의 전환을 요구한다 [2].

3.2 시간 안정성 및 cross-session 인증 연구

연구	데이터/설정	핵심 발견	본 연구에 반영할 요소
Seeing Red [4]	15 명, 6-11 세션, smartphone camera fingertip PPG	충분한 aggregation 시 EER 약 8%, cross-session 평균 EER 약 20%	외부 검증 및 성능 저하 기준선
PBGAN [3]	PPG verification, single-/two-session 평가	시간 변화로 인한 intra-user variability 를 GAN augmentation 으로 완화; two-session EER 11.5%	생성보다 실제 session embedding 정렬을 선택
Continuous Authentication via Wrist PPG [5]	총 155 명, across-session/HR interval 평가	시간과 HR 변화에서 신뢰성 검증 필요; subject-exclusive protocol 강조	평가 설계와 verification 지표
Robust PPG Authentication [6]	LAUREATE, 44 명, 13 주/52 세션, 1D CNN identification	시간 경과와 단조 하락은 없지만 사용자·상태별 변동 큼	문제를 단순 time decay 가 아니라 session shift 로 재정의

Alecci et al. [6]의 결과는 본 연구의 표현을 조정하게 한다. 즉, “시간이 지날수록 PPG 인증이 무조건 나빠진다”가 아니라, “세션이 바뀌면 동반되는 상태·품질·환경 변화로 인해 사용자 표현의 분포가 이동한다”가 더 방어 가능한 문제 정의다. 따라서 interval 별 분석은 수행하되, 시간에 따른 단조 악화를 연구 가정으로 두지 않는다.

3.3 표현 학습 및 adaptation 연구에서 가져올 요소

연구	원래 목적	유용한 아이디어	그대로 사용하지 않는 이유 / 변환 방식
PAPAGEI [7]	공개 대규모 PPG foundation model	PAPAGEI-S encoder, IPA/sVRI/SQI 보조 목표, 10 초/125 Hz pipeline	사용자 인증 태스크가 아니므로 cross-session verification fine-tuning 추가

연구	원래 목적	유용한 아이디어	그대로 사용하지 않는 이유 / 변환 방식
GAUL [8]	새 사용자 HR 추정 domain adaptation	모든 domain/sample 의 신뢰도가 같지 않다는 관점	HR pseudo-label weighting 은 인증에 부적합; session centroid alignment 와 SQL weighting 으로 변환
Daily-life validation [9]	일상 wrist PPG 와 ECG 간 HR/HRV 검증	활동·coverage·착용 위치가 품질에 영향, 저품질 신호를 별도 분석해야 함	상태 예측 문제는 확장하지 않고 SQL 기반 품질 처리에만 반영
Evaluation pitfalls [10]	PPG 기반 BP 예측 평가 오류 분석	window/record leakage 와 지나친 clean filtering 위험	인증 평가에도 session-disjoint split 과 데이터 유출을 보고로 적용

3.4 문헌에서 설계 결정으로 이어지는 근거 사슬

문헌 관찰	설계 결정	실험으로 확인할 내용
Cross-session 에서 EER 이 악화될 수 있음 [3-5]	cross-session pair 를 핵심 positive 로 사용	일반 SupCon 대비 EER/Delta EER 개선
시간 자체보다 세션별 상태·품질 변동이 중요할 수 있음 [6, 9]	SQL weighting 및 품질 구간별 보고	low-quality bin 에서의 견고성
PPG-specific morphology objective 가 downstream 에 유용 [7]	morphology auxiliary head 추가	identity margin 및 성능 변화
샘플/세션 누수는 성능을 인위적으로 높임 [10]	완전한 session/subject 분리 평가	split 별 성능 차이를 투명하게 보고
표준 지표 부족 [2]	EER/TAR@FAR/FAR/FRR 중심 보고	재현 가능한 threshold protocol

4. 후보 데이터셋 비교와 선정 전략

4.1 선정 기준

- 직접 수집 없이 접근 가능하거나 공개 원자료에서 재구성 가능해야 한다.
- 동일 사용자의 두 개 이상 session 이 존재하여 cross-session enrollment/probe 구성이 가능해야 한다.
- 사용자 수와 시간 간격이 충분하여 모델 학습과 interval analysis 가 가능해야 한다.
- 세션 단위 분할과 subject-disjoint 평가를 수행할 수 있는 metadata 가 있어야 한다.
- 접근 제한 또는 디바이스 차이가 논문 주장 범위를 제한하는 경우 이를 명시한다.

4.2 후보 데이터셋 비교

데이터셋	규모/세션	환경/센서	접근성 확인	본 연구에서의 위치
SigD [2,11-13]	232 명; 2 회 이상; 세션 간 격 3 시간-3000 일; 약 5.7 분 구간	임상/MIMIC-III waveform 기반 PPG	GitHub 추출 코드와 PhysioNet 원자료 경로 확 인. PhysioNet 승인 절차 필요 가능	주 데이터셋: 장·단기 cross-session 검증
Seeing Red [4,14]	15 명; 사용자당 6-11 세션; 세션당 30 초 영상	iPhone X camera fingertip PPG	공식 GitHub 에서 데이 터/코드 다운로드 확인	즉시 파일럿 및 센서 도메인 외부 검증
LAUREATE [6]	44 명; 13 주; 52 세션; 1,400 시간 이상	Empatica E4 wrist PPG; self-report state	저자 접촉 및 data- sharing agreement 필요	후속 state-aware 분석만 고려
WF-PPG [2]	27 명; 6 세션; 4 분	wrist contact pressure 제어	review 표에 데이터셋 명시	pressure/quality 분석용 보조 후보
WildPPG [2]	16 명; 평균 13.5 시간	실제 활동·다중 위치	review 표에 후보로 정리	현실 노이즈/일반화 후속 후보

4.3 최종 선정: SigD 를 주 데이터셋으로, Seeing Red 를 실행 안전망으로

SigD 는 사용자가 직접 수집하지 않아도 공개 원자료와 공개 코드 경로를 통해 재구성 가능한 구조이며, 232 명과 장기간 세션 간격을 제공한다는 점에서 본 연구의 핵심 질문에 가장 직접적으로 맞는다 [2, 11-13]. SigD GitHub 는 waveform 을 PhysioNet 의 MIMIC-III Waveform Database Matched Subset 에서, 개인 정보 연결을 MIMIC-III 임상 데이터에 서 얻는 노트북 및 record 목록을 제시한다 [12, 13].

단, 이 선택은 “웨어러블 일상환경” 전체를 주장하게 해주는 것은 아니다. SigD 는 임상 데이터 기반이므로, 연구의 핵심 주장은 “publicly reconstructable multi-session clinical PPG 에서의 cross-session verification stability”로 제 한한다. 소비자 디바이스로의 확대 가능성은 Seeing Red 외부 검증 결과가 있을 때만 조심스럽게 논의한다.

데이터셋 실행 전략

Track A (최종 실험): PhysioNet 접근 승인을 확보해 SigD 를 구성하고 주 결과를 산출한다. Track B (승인 대기 중 즉시 구현): Seeing Red 에서 preprocessing, pair sampling, 모델 학습, EER 평가 코드 전체를 먼저 완성한다. 이 후 SigD 가 확보되면 dataset loader 만 교체하여 동일 프로토콜을 적용한다.

4.4 데이터 접근 및 재현성 기록 항목

기록 항목	SigD 적용 시 반드시 남길 내용
데이터 출처	SigD 공개 코드 repository commit/hash, PhysioNet MIMIC-III


기록 항목	SigD 적용 시 반드시 남길 내용
	waveform/clinical 버전
대상 선정	추출 성공 subject 수, 2 회 이상 session 보유 subject 수, 제외 규칙
신호 구조	PPG channel name, 원 sampling frequency, 각 session 유효 길이
세션 간격	최소/최대/중앙값/분포, interval bin 생성 기준
개인정보/약정	PhysioNet 승인 및 데이터 사용 약정 준수, 원신호 외부 공유 금지 여부
재현성 산출물	subject/session index 만 포함한 split manifest 와 preprocessing configuration 공개

5. 제안 방법론: SIM-PPG

5.1 모델 설계 철학

SIM-PPG(Session-Invariant Morphology-Preserving PPG Verification Network)는 세션 간 분포 이동을 제거하
되, 사용자 구분에 유용한 파형 형태학 정보를 보존하는 verification encoder 다. 모델은 PPG-specific 사전학습
backbone(PAPAGEI-S)을 활용하고, cross-session genuine pair 만을 중심으로 embedding 을 정렬하며, quality
와 morphology 를 보조 신호로 사용한다.

SIM-PPG: Session-Invariant Morphology-Preserving Verification Network



$$L_{total} = L_{CS-SupCon}(\text{weighted}) + \lambda_{align} L_{align} + \lambda_{morph} L_{morph}$$

그림 2. 제안 SIM-PPG 구조. 모든 구성요소는 cross-session verification 안정성 개선을 위한 단일 목표에 귀속된다.

5.2 입력과 encoder

구성	기본값	선정 이유
Input segment	10 초 non-overlapping PPG window	PAPAGEI 전처리와 직접 호환되며 짧은 인증 지연 유지
Sampling rate	125 Hz (SigD/MIMIC 기준)	PAPAGEI pretraining 의 공통 resampling rate 와 일치
Encoder	PAPAGEI-S 5M pretrained backbone	공개 PPG 대규모 pretraining 과 morphology-aware representation 활용
Projection head	512 -> 256 -> 128, L2 normalization	verification cosine similarity 용 compact embedding
Verification score	cosine similarity(z_enroll, z_probe)	threshold 기반 FAR/FRR/EER 평가에 자연스러움

5.3 핵심 목표 1: Cross-Session Identity Contrastive Learning

동일 사용자라도 동일 세션의 인접 window 는 매우 유사하여 쉬운 positive 가 된다. 이를 주 학습 신호로 사용하면 cross-session 성능을 과대평가하거나, 정작 세션 이동에 대한 학습이 약해질 수 있다. 따라서 주 positive pair 는 반드시 서로 다른 세션에서 선택한다.

Pair 유형	정의	학습 기여
Cross-session genuine (주 positive)	$u_i = u_j, s_i \neq s_j$	embedding 을 가깝게 정렬; 가장 높은 비중
Within-session genuine (보조)	$u_i = u_j, s_i = s_j$	warm-up 또는 안정화용 소량 사용
Impostor negative	$u_i \neq u_j$	사용자 간 margin 유지
Hard negative	현재 score 가 높은 impostor pair	오인 허용 위험 영역을 집중 학습

품질 가중 supervised contrastive loss 의 형태는 다음과 같이 정의한다.

Identity loss

$$L_{CS-SupCon}^Q = - \sum_i (1/|P(i)|) \sum_{\{p \in P(i)\}} w_{ip} \log [\exp(\text{sim}(z_i, z_p)/\tau) / \sum_{a \neq i} \exp(\text{sim}(z_i, z_a)/\tau)]$$

$P(i)$ 는 동일 사용자이면서 서로 다른 세션의 positive 집합이고, w_{ip} 는 신호 품질을 반영한 pair weight 다.

5.4 핵심 목표 2: Within-User Session Centroid Alignment

Contrastive loss 는 개별 pair 를 정렬하지만 session-level cluster 이동을 직접 줄이지는 않는다. 각 사용자-세션의 평균 embedding 중심을 사용자 전체 중심에 가깝게 만드는 alignment loss 를 추가하면, 세션에 따라 genuine score 가 급격히 변하는 현상을 억제할 수 있다.

Session alignment loss

$$\mu_{u,s} = \text{mean}\{z_i \mid \text{user}=i \text{ belongs to } u, \text{ session}=s\}$$
$$\mu_u = \text{mean}\{\mu_{u,s} \mid s \text{ in sessions of } u\}$$
$$L_{\text{align}} = \sum_u \sum_s \|\mu_{u,s} - \mu_u\|_2^2$$

5.5 핵심 목표 3: Morphology Preservation Auxiliary Learning

세션 정보를 제거하는 정렬만 강하게 적용하면, identity 를 구분하는 PPG morphology 까지 평탄화될 위험이 있다. PAPAGEI-S 가 활용한 morphology 관련 지표를 auxiliary target 으로 두어 encoder 가 형태학적 의미를 유지하도록 한다 [7].

지표	의미	구현 처리
sVRI	systolic peak 전후 평균 파형 반응 비율	모든 계산 가능 segment 에서 회귀 target 으로 사용
IPA	dicrotic notch 기준 systolic/diastolic area 관계	notch 탐지가 신뢰 가능한 segment 에만 masked loss 적용
SQI	skewness 기반 신호 품질 indicator	품질 예측 auxiliary + pair weighting 의 근거

Morphology loss

$$L_{\text{morph}} = \text{SmoothL1}(sVRI_{\text{hat}}, sVRI) + m_{\text{IPA}} * \text{SmoothL1}(IPA_{\text{hat}}, IPA) + \text{SmoothL1}(SQI_{\text{hat}}, SQI)$$

m_{IPA} 는 notch 검출이 유효할 때만 1 인 mask 다.

5.6 Signal Quality-Aware Pair Weighting

일상 PPG 검증 연구는 움직임, 자세, coverage, 착용 위치에 따라 PPG의 신뢰성이 달라짐을 보여준다 [9]. 본 연구의 목적은 좋은 신호만 남기는 것이 아니라, 품질 변동이 있는 세션에서도 인증을 안정화하는 것이다. 따라서 flatline 등 명백히 무효한 segment만 제거하고, 나머지는 SQL 기반 weight로 학습 기여도를 조절한다.

품질 weight의 예시 정의

$$q_i = \text{clip}(\text{rank_normalize}(\text{SQL}_i), q_{\min}, 1), \quad q_{\min} = 0.25$$

$$w_{ij} = \sqrt{q_i \cdot q_j}$$

저품질 segment는 배제하지 않으며, 학습 가중치와 결과 분석 구간에 반영한다.

5.7 최종 학습 목적함수

SIM-PPG final objective

$$L_{\text{total}} = L_{\text{CS-SupCon}}^Q + \lambda_{\text{align}} \cdot L_{\text{align}} + \lambda_{\text{morph}} \cdot L_{\text{morph}}$$

권장 초기 탐색값: λ_{align} in {0.01, 0.05, 0.1}, λ_{morph} in {0.05, 0.1, 0.2}, τ in {0.05, 0.1, 0.2}. 값은 validation subjects에서만 선택한다.

6. 데이터 전처리 및 학습 샘플 구성

6.1 SigD 구성 단계

1. SigD repository의 record list 및 notebook을 이용하여 대상 subject/session 목록을 재구성한다.
2. PhysioNet waveform record에서 PPG channel을 로드하고, 임상 metadata가 허용되는 경우 age/gender와 session interval을 연결한다.
3. 각 subject가 최소 두 개의 유효 session을 갖는지 확인하고, session별 유효 신호 길이와 품질 통계를 기록한다.
4. 동일한 preprocessing pipeline을 train, validation, test에 적용하되, split은 window 생성 전에 subject/session 기준으로 고정한다.

6.2 기본 전처리 파이프라인

순서	처리	기본 설정	누수/과정 기록
1	Channel selection	PPG/PLETH channel만 사용	record별 channel availability 저장

순서	처리	기본 설정	누수/과정 기록
2	Bandpass filtering	0.5-12 Hz; PAPAGEI 와 호환	필터 파라미터 고정
3	Resampling	125 Hz	원 fs 와 변환 정보 저장
4	Segmentation	10 초 non-overlap 기본	split 이전 window shuffle 금지
5	Normalization	window 별 z-score	train/test 동일 처리
6	Unusable rejection	flatline > 25% 또는 NaN 손상만 제외	제외율 전체·세션별 보고
7	Morphology/SQI	sVRI, IPA(mask), SQI 계산	계산 실패율 기록

6.3 Window 길이와 sample construction

조건	용도	고정/비교
10 초 window	주 실험 입력; pretrained encoder 와 일치	고정 기본
5 초 window	인증 응답 지연 축소 가능성	ablation
30 초 window	aggregation 으로 노이즈 완화 가능성	ablation
Enrollment aggregation K={1,3,5}	등록 템플릿 평균화의 효과	실제 사용 조건 분석
Decision aggregation M={1,3,5}	연속 probe score 평균화 효과	보조 분석

6.4 Data leakage 방지 규칙

PPG BP 평가 연구는 같은 record 또는 overlapping window 가 train/test 에 나뉘어 들어가면 성능이 크게 부풀려질 수 있음을 보였다 [10]. 인증에서는 이 위험이 더 크며, 동일 사용자의 파형 패턴 자체가 leakage source 가 된다. 다음 규칙을 구현 단계에서 assertion 으로 강제한다.

- Subject-disjoint 주 평가에서는 train/validation/test user ID 가 완전히 겹치지 않는다.
- Enrollment session 과 probe session 은 동일 사용자 내에서도 완전히 분리한다.
- Overlap window 는 만들지 않는 것을 기본으로 하며, 필요 시 같은 split 안에서만 존재하게 한다.
- Validation 에서 정한 threshold 와 hyperparameter 를 test 에서 변경하지 않는다.
- 품질 필터링 전후의 subject/session/window 수를 모두 표로 보고한다.

7. 학습 및 평가 프로토콜

7.1 주 태스크: Open-set 스타일의 subject-disjoint verification

모델이 학습 과정에서 보지 못한 신규 사용자에게도 등록 템플릿 기반 인증이 가능한지 검증한다. 이는 단순히 데이터셋의 232 개 ID 를 분류하는 closed-set identification 보다 실제 인증 제품의 등록/인증 흐름에 가깝다.

분할	대상	역할
Training subjects	전체 subject 의 60% (가능하면 gender/age stratified)	encoder fine-tuning 및 pair 학습
Validation subjects	20%	threshold, lambda, epoch, early stopping 선택
Test subjects	20%	최종 EER/FAR/FRR/TAR 보고; 학습 중 절대 미노출

Primary evaluation flow

Test user u: earliest valid session -> enrollment template; later sessions -> genuine probes; other test users later sessions -> balanced impostor probes. Threshold is fixed using validation subjects only. Time-gap and SQL bins are analyzed after the primary verification evaluation.

7.2 Enrollment / probe 구성

항목	정의
Enrollment	평가 사용자의 시간상 최초 유효 세션에서 K 개 window embedding 을 평균하여 template 생성
Genuine probe	동일 사용자의 후속 session window 또는 aggregated window
Impostor probe	다른 평가 사용자의 후속 session window; 사용자별 균형 샘플링
Threshold	Validation set 에서 EER threshold 및 FAR=1% threshold 를 각각 확정 후 test 에서 고정
Score aggregation	window score 단위 결과를 기본으로 보고하고, M-window 평균 결과를 실사용 보조 분석으로 추가

7.3 Protocol 세트

Protocol	설정	목적	논문 내 비중
P0: Within-session reference	같은 session 내 분리된 앞/뒤 구간; overlap 금지	쉬운 조건 성능과 Delta EER 산출	Reference
P1: Cross-session verification	첫 session enrollment, 후속 session probe	핵심 성능 평가	Primary
P2: Time-gap stratified	세션 간격을 quantile/bin 으로 분류	간격과 성능 분산의 관계 분석	Primary analysis
P3: Quality-stratified	SQL low/mid/high 구간별 probe 평가	quality weighting 의 효과 검증	Primary analysis
P4: External validation	SigD 학습/설계 후 Seeing Red 에 적용 또는 별도 fine-tune	센서 도메인 차이에 대한 범위 확인	Secondary

7.4 다중 seed 와 통계적 보고

- 동일 split 에서 5 개 seed(예: 42, 52, 123, 777, 2026)로 학습하고 평균±표준편차를 보고한다.
- 최종 test metric 은 subject 단위 bootstrap 1,000 회로 95% confidence interval 을 보고한다.
- Ablation 차이는 paired bootstrap 또는 동일 split/seed paired comparison 으로 제시한다.
- 사용자별 결과 분포를 병기하여 일부 사용자만 좋아지는 현상을 감춘 평균 성능을 피한다.

8. 실험 설계와 비교 실험 목록

8.1 최소 구현에서 최종 모델까지의 단계적 실험

단계	모델/실험	목적	완료 기준
E0	Dataset audit + split manifest	유효 subject/session/interval/quality 확인	누수 없는 manifest 저장
E1	Handcrafted morphology + cosine/SVM	전통 기준선	P0/P1 EER 산출
E2	1D Siamese CNN from scratch	간단 metric learning baseline	EER 및 ROC 저장
E3	PAPAGEI-S frozen + cosine	사전학습 embedding 의 직접 전이 성능	fine-tuning 전 기준선
E4	PAPAGEI-S + generic SupCon	participant-aware contrastive baseline	일반 contrastive 대비 비교

단계	모델/실험	목적	완료 기준
E5	Cross-session SupCon only	핵심 pair strategy 효과	E4 대비 개선 검증
E6	E5 + centroid alignment	session shift 직접 억제	Delta EER 감소
E7	E6 + morphology preservation	identity 정보 보존	TAR@FAR 및 margin 개선
E8	E7 + SQL weighting = SIM-PPG	최종 제안 모델	품질 구간별 안정성 포함 최종 결과
E9	Seeing Red external/pilot validation	센서/획득 방식 변화 범위 확인	동일 평가 코드 재사용

8.2 필수 baseline 목록

Baseline	입력/학습 방식	비교 의미	필수 여부
Morphology Features + Cosine/SVM	peak/area/interval handcrafted vector	전통 파형 기반 접근 기준선	필수
1D Siamese CNN	pair BCE 또는 contrastive	경량 end-to-end verification 기 준선	필수
PAPAGEI-S Frozen	pretrained embedding + cosine	foundation representation 자 체 성능	필수
PAPAGEI-S Generic SupCon	same user positive, session 조 건 없음	제안 pair mining 의 차별성	필수
PBGAN-like augmentation	재현 가능 시 synthetic augmentation	기존 time-stability 접근과 비교	선택
SIM-PPG	최종 제안 구조	본 연구 모델	필수

8.3 Ablation study 목록

Ablation	비교 설정	검증 질문
A1 Pair definition	Generic SupCon vs cross-session-only positives	다른 세션 pair 를 명시하는 것이 유효한가?
A2 Alignment	w/o vs w/ L_align	session centroid 정렬이 genuine 안정성을 높이는가?
A3 Morphology	w/o vs w/ L_morph	과도한 invariance 를 방지하는가?
A4 Quality	reject-all-clean vs no-weight vs SQL-	현실 품질을 남기면서 개선 가능한가?

Ablation	비교 설정	검증 질문
	weighted	
A5 Backbone	random CNN vs PAPAGEI-S frozen vs fine-tuned	공개 pretraining의 기여는 무엇인가?
A6 Window length	5/10/30 초	지연-성능 trade-off는 무엇인가?
A7 Template size	K=1/3/5 enrollment windows	등록 부담 대비 안정성 변화는?
A8 Time gap	interval bins/quantiles	성능 저하가 시간 간격에 단조적인가?

8.4 Hyperparameter 탐색 범위(초기안)

항목	탐색 범위	선택 방법
Learning rate	{1e-5, 3e-5, 1e-4} (pretrained fine-tune)	validation EER 최소
Batch 구성	user 16명 x session-positive 2쌍 또는 가능한 최대	GPU 메모리와 pair 다양성
Embedding dim	{64, 128, 256}	validation EER/TAR
Temperature tau	{0.05, 0.1, 0.2}	validation EER
lambda_align	{0.01, 0.05, 0.1}	Delta EER와 user margin
lambda_morph	{0.05, 0.1, 0.2}	validation TAR@FAR
q_min	{0, 0.25, 0.5}	quality-bin performance
Early stopping	patience 10, validation EER	test 비사용

9. 평가 지표 및 결과 보고 양식

9.1 Primary biometric metrics

지표	정의/계산 관점	보고 이유
EER (Primary)	FAR = FRR가 되는 threshold의 오류율	PPG verification 문헌과 직접 비교 가능한 핵심 지표
TAR@FAR=1%	FAR를 1%로 제한했을 때 genuine acceptance	낮은 허용 공격률에서 usability 평가

지표	정의/계산 관점	보고 이유
ROC-AUC	threshold 전 범위의 genuine/impostor 분리 성능	단일 threshold 의존성 완화
FAR / FRR	비인가 허용률 / 정당 사용자 거부율	보안과 usability trade-off 명시
GAR	1 - FRR	허용률 관점 보고; review 권고와 일치

9.2 Stability and reliability metrics

지표	산출 방식	해석
Delta EER	EER_cross - EER_within	세션 변화로 인한 성능 손실; 작을수록 우수
Interval-binned EER	세션 간격 구간별 EER와 CI	시간 간격의 영향이 단조적인지 탐색
Quality-stratified EER	SQL low/mid/high probe 별 EER	quality weighting의 실용적 효과
User-wise EER/FRR distribution	평가 사용자별 metric 분포	일부 사용자에게 대한 편중 확인
Score margin	mean genuine score - mean impostor score	embedding 분리력과 정렬 부작용 분석

9.3 최종 논문에 포함할 표와 그림 템플릿

결과 산출물	포함 내용
Table R1 Dataset statistics	split 별 subject/session/window 수, interval 분포, excluded segment 비율
Table R2 Main result	모델별 P0/P1 EER, TAR@FAR=1%, ROC-AUC, Delta EER, CI
Table R3 Ablation	각 loss 및 pair 구성 제거 시 P1 성능 변화
Table R4 Quality analysis	SQL bin 별 window 수 및 EER/FRR
Figure R1 ROC/DET curve	baseline 과 SIM-PPG 의 cross-session 비교
Figure R2 Score distributions	genuine vs impostor score density
Figure R3 Time-gap plot	interval bin 별 EER와 confidence interval
Figure R4 UMAP	색=사용자, marker=세션; 정렬 전/후 비교
Figure R5 User-wise boxplot	사용자별 FRR 또는 EER 변동 분포

10. 연구의 차별성 및 노벨티

10.1 무엇이 새로운가

핵심 novelty statement

본 연구는 공개 multi-session PPG 에서 실제 verification 평가를 구성하고, 동일 사용자-다른 세션 positive pair 를 명시적으로 학습하면서 session centroid 이동을 줄이되 PPG morphology 와 signal quality 를 보존하는 session-invariant authentication embedding 학습 방법을 제안한다.

기존 방향	기존 연구가 한 일	SIM-PPG 의 차별점
Feasibility/분류 모델	동일/근접 세션에서 identity classification 성 능 확인	신규 사용자 subject-disjoint verification 과 cross-session threshold 평가
PBGAN [3]	synthetic time-stable signal 을 생성해 augmentation	실제 세션 embedding 을 직접 정렬하며 생성 데이터 의존성 없음
Robust PPG Auth [6]	시간·사용자·상태 변동의 영향 분석	분석에서 멈추지 않고 session-invariant representation 을 학습
PAPAGEI [7]	일반 PPG downstream 용 morphology- aware FM	공개 backbone 을 cross-session biometric verification 에 목적 특화 fine-tuning
GAUL [8]	HR 회귀에서 target subject domain adaptation	인증의 동일 사용자 session sub-domain alignment 로 문제 맞춤 변환
Quality validation [9]	일상 환경 신호 품질의 영향 분석	SQI 를 학습 weight 와 성능 구간 분석에 직접 연결

10.2 지나친 novelty 주장 방지

- “최초의 PPG foundation model” 또는 “최초의 cross-session PPG dataset”은 본 연구의 기여가 아니며, 해당 선행연구의 기여로 인용한다.
- “실제 wearable 환경에서 완전 검증”이라는 주장은 SigD 단독으로는 하지 않는다. 임상 기반 PPG 라는 범위를 명시한다.
- “state variability 해결”은 LAUREATE 등을 이용한 추가 실험이 없는 한 주장하지 않는다.
- 주요 기여는 새로운 데이터 수집이 아니라, 공개 데이터 기반의 엄격한 verification protocol 과 session-invariant representation design 이다.

10.3 논문 Introduction 에 사용할 기여점 초안

- We formulate cross-session PPG authentication as a subject-disjoint verification problem using publicly reconstructable multi-session PPG data, avoiding window- and session-level leakage.
- We propose SIM-PPG, a morphology-preserving contrastive framework that explicitly aligns genuine samples across sessions while retaining identity-relevant PPG structure.
- We introduce quality-aware training and interval-/quality-stratified evaluation to distinguish representation robustness from performance inflated by clean-signal filtering.
- We conduct systematic comparisons against handcrafted, Siamese, frozen foundation-model, and generic contrastive baselines under fixed-threshold biometric metrics.

11. 실제 구현 로드맵

11.1 구현 단계별 산출물

주차/단계	주요 작업	산출물
Phase 0	PhysioNet/SigD 접근 확인; Seeing Red 다운 로드; repository 고정	DATA_ACCESS.md, source manifest
Phase 1	dataset loader 및 signal audit 구현	dataset_stats.csv, quality histogram, split_manifest.csv
Phase 2	preprocessing/morphology/SQI 함수 단위 테스트	processed index, preprocessing config, QC plot
Phase 3	baseline 3 종 구현 및 P0/P1 평가	baseline_results.csv, ROC curves
Phase 4	Cross-session SupCon 및 centroid alignment 구현	checkpoint, ablation A1-A2
Phase 5	Morphology head 와 SQI weighting 추가	SIM-PPG checkpoint, A3-A4
Phase 6	다중 seed, CI, interval/quality 분석	main tables, figure set
Phase 7	Seeing Red 외부 검증 또는 파일럿 결과 정리	external_results.csv
Phase 8	논문 초본 작성	Methods/Experiments/Results 초안

11.2 권장 프로젝트 폴더 구조

실험 코드 구성 예시

ppg_auth/
configs/ # dataset, preprocessing, model, protocol YAML

```

data_raw/      # 직접 배포 금지 데이터; 로컬 전용
metadata/      # split manifest, session interval, QC index
src/
  datasets/    # sigd.py, seeing_red.py
  preprocessing/ # filter.py, segment.py, morphology.py, quality.py
  models/      # papagei_wrapper.py, sim_ppg.py, losses.py
  protocols/   # enrollment_probe.py, threshold.py
  metrics/     # eer.py, tar_far.py, bootstrap.py
  experiments/ # baseline/, ablation/, main/, external/
  results/     # csv, figures, tables
  scripts/     # run_baselines.sh, run_main.sh, run_ablation.sh
  docs/        # access record, protocol notes, draft tables

```

11.3 구현 시 먼저 작성할 검증용 assertion

- assert set(train_subjects) is disjoint from set(val_subjects) and set(test_subjects)
- assert enrollment_session != probe_session for every genuine cross-session trial
- assert no raw timestamp/window ID appears in two splits
- assert test threshold was loaded from validation result file and not re-estimated
- assert exclusions and usable-window ratios are written before training begins

12. 리스크, 한계 및 대안 전략

리스크	영향	대응 방안
SigD/MIMIC 접근 승인 지연	주 실험 착수 지연	Seeing Red 로 전처리·모델·평가 코드를 먼저 완성; 이후 loader 교체
SigD 실제 유효 session 수 부족	pair 다양성 및 interval 분석 약화	audit 후 최소 유효 기준 조정; interval bin 을 quantile 기반으로 변경
임상 PPG 와 consumer PPG 의 도메인 차이	웨어러블 일반화 주장 제한	주장 범위 제한; Seeing Red 를 외부 센서 보조 검증으로 사용
IPA notch 검출 실패	morphology auxiliary 불안정	masked IPA loss; sVRI/SQI 만 사용하는 ablation 제공
저품질 신호가 학습을 방해	성능 저하/학습 불안정	flatline 최소 제거 + SQI weighting + quality-stratified 보고
PAPAGEI fine-tuning 과적합	소규모 데이터에서 일반화 약화	frozen baseline, 부분 unfreeze, 작은 LR, early stopping 비교

리스크	영향	대응 방안
Demographic imbalance	성능 해석 편향	가능한 경우 subgroup confidence interval 보고; 개선 주장 보류

핵심 한계 선언

SigD 기반 결과는 cross-session 안정성 연구에는 강하지만, 임상 센서 기반 데이터라는 한계를 갖는다. 따라서 본 연구의 1 차 결론은 “공개 재구성 가능한 multi-session PPG 에서의 검증 안정성 개선”으로 한정하며, 웨어러블 일상 사용성이나 상태 적응성을 최종적으로 입증하는 연구로 과장하지 않는다.

13. 향후 논문 초본으로의 전환 구조

실험이 완료되면 아래의 뼈대를 그대로 논문 초본으로 전환할 수 있다. 본 보고서의 각 절은 논문의 어떤 부분으로 이동할 지 미리 정렬되어 있다.

논문 절	작성할 내용	본 보고서 기반 자료
Abstract	문제, 방법, dataset, 핵심 수치(EER/TAR) 1-2 문장	최종 결과 후 작성
1. Introduction	cross-session gap, 공개 데이터 필요성, 기여 점	2, 3, 10 절
2. Related Work	PPG authentication, stability, SSL/FM, evaluation leakage	3 절
3. Problem Formulation	verification trial, enrollment/probe, session shift	2, 7 절
4. Proposed Method	SIM-PPG architecture, loss, preprocessing	5, 6 절
5. Experimental Setup	datasets, split, baselines, metrics, hyperparams	4, 7-9 절
6. Results	main/ablation/quality/interval/external 결과	결과 템플릿
7. Discussion	성능 해석, 제한점, deployment implication	10, 12 절
8. Conclusion	단일 문제 해결 성과와 후속 확장	최종 실험 후 작성

13.1 실험 성공 판단 기준

판정	조건
강한 성공	SIM-PPG 가 필수 baseline 모두보다 cross-session EER 을 유의하게 낮추고, Delta EER 및 TAR@FAR=1%도 개선
부분 성공	EER 개선은 작지만 quality 또는 long-gap bin 에서 일관된 개선이 확인됨
설계 수정 필요	within-session 만 개선되고 cross-session 은 개선되지 않거나, morphology/alignment 추가가 성능을 악화
논문 방향 전환	데이터 유효성/세션 구조가 충분하지 않아 문제를 검증할 수 없음; Seeing Red 또는 다른 공개 dataset 으로 범위 재정의

참고문헌

[1] Li, L., Chen, C., Pan, L., Zhang, L.Y., Wang, Z., Zhang, J., & Xiang, Y. (2023). A Survey of PPG's Application in Authentication. Computers & Security, 135, 103488.

[2] Aguilar, D., Martínez-Cruz, A., Ramírez-Gutiérrez, K.A., & Morales-Sandoval, M. (2025). PPG-based biometric authentication: A review on architectures, datasets, attacks and security challenges. Computational and Structural Biotechnology Journal, 28, 511-528.

[3] Hwang, D.Y., Taha, B., & Hatzinakos, D. (2021). PBGAN: Learning PPG Representations From GAN for Time-Stable and Unique Verification System. IEEE Transactions on Information Forensics and Security, 16, 5124-5137.

[4] Lovisotto, G., Turner, H., Eberz, S., & Martinovic, I. (2020). Seeing Red: PPG Biometrics Using Smartphone Cameras. CVPR Workshops.

[5] Wu, J., Luo, X., Chen, S., Lyu, Y., Ji, X., Meng, Y., & Wang, D. (2025). Continuous Authentication via Wrist Photoplethysmogram: An Extensive Study. IEEE Transactions on Mobile Computing, 24(2), 525-538.

[6] Alecci, L., Zanzi, A., Laporte, M., Alchieri, L., Abdalazim, N., De Felice, G., & Santini, S. (2025). Robust PPG Authentication: The Role of Temporal, Individual, and State Variability. UbiComp Companion 2025.

[7] Pillai, A., Spathis, D., Kawsar, F., & Malekzadeh, M. (2025). PAPAGEI: Open Foundation Models for Optical Physiological Signals. ICLR 2025.

[8] Kim, J., Cho, H., Lee, M., & Kim, S.B. (2025). Multi-source partial domain adaptation with Gaussian-based dual-level weighting for PPG-based heart rate estimation. Knowledge-Based Systems, 309, 112769.

[9] Rehman, R.Z.U., Chatterjee, M., Manyakov, N.V., et al. (2024). Assessment of Physiological Signals from Photoplethysmography Sensors Compared to an Electrocardiogram Sensor: A Validation Study in Daily Life. Sensors, 24, 6826.

[10] Mehta, S., Kwatra, N., Jain, M., & McDuff, D. (2024). Examining the challenges of blood pressure estimation via photoplethysmogram. Scientific Reports, 14, 18318.

- [11] Li, L., Chen, C., Pan, L., Zhang, J., & Xiang, Y. (2023). SigD: A Cross-Session Dataset for PPG-based User Authentication in Different Demographic Groups. IJCNN 2023, 1-8.
- [12] SigD public code repository. NasTul/SigD, GitHub. Accessed 2026-05-22. Repository provides record extraction and MIMIC-III retrieval notebook.
- [13] PhysioNet. MIMIC-III Waveform Database Matched Subset, version 1.0. Accessed 2026-05-22.
- [14] Seeing Red official dataset/code repository. ssloxford/seeing-red, GitHub. Accessed 2026-05-22.
- [15] Ayeswarya, S., & Singh, K.J. (2024). A Comprehensive Review on Secure Biometric-Based Continuous Authentication and User Profiling. IEEE Access, 12, 82996-83021.

부록 A. 알고리즘 의사코드

A.1 Training procedure

Algorithm 1. SIM-PPG training

Input: train subjects U_{train} , sessions S_u , pretrained encoder E , hyperparameters

1. For each epoch:
2. Sample a batch of users u from U_{train} .
3. For each user, sample two different sessions $s_a \neq s_b$.
4. Draw PPG windows x_a, x_b and compute SQL/morphology targets.
5. Obtain embeddings $z = P(E(x))$ and morphology predictions.
6. Form cross-session genuine pairs and impostor/hard-negative pairs.
7. Compute quality-weighted cross-session supervised contrastive loss.
8. Compute within-user session centroid alignment loss.
9. Compute masked morphology preservation loss.
10. Update model using L_{total} .
11. Select checkpoint using validation-subject cross-session EER only.

Output: trained encoder and locked verification thresholds.

A.2 Test-time verification procedure

Algorithm 2. Evaluation on unseen users

Input: unseen test subjects, locked encoder, thresholds from validation

1. For each test user u , select earliest valid session as enrollment.
2. Build template t_u by averaging K normalized embeddings from enrollment.
3. For each later session, compute genuine probe scores $\cos(t_u, z_{\text{probe}})$.
4. For every other user v , compute balanced impostor probe scores $\cos(t_u, z_v)$.
5. Evaluate fixed-threshold FAR/FRR/TAR; independently calculate ROC and EER.
6. Repeat analyses by time-gap bin and SQL bin; bootstrap by subject.

Output: main metric table, confidence intervals, plots, per-user error analysis.

부록 B. 실험 수행 체크리스트

영역	체크 항목	완료
----	-------	----

데이터 접근	SigD/PhysioNet 승인 상태와 약정 기록	☐
데이터 접근	Seeing Red 직접 다운로드 및 파일 hash 저장	☐
Audit	subject/session/interval/quality 통계 생성	☐
Split	subject-disjoint train/val/test manifest 고정	☐
Leakage	overlap 및 timestamp 중복 assertion 통과	☐
Preprocessing	필터/리샘플/제외율/모폴로지 계산 로그 저장	☐
Baseline	Handcrafted, Siamese, PAPAGEI frozen, Generic SupCon 실행	☐
Proposed	SIM-PPG main experiment 5 seeds 실행	☐
Ablation	A1-A8 비교 실험 수행	☐
Metrics	EER, TAR@FAR, AUC, FAR/FRR, Delta EER, CI 산출	☐
Analysis	time-gap, SQL, user-wise 결과 시각화	☐
Paper	표/그림 번호 및 주장-근거 일치 확인	☐

부록 C. 실험 결과 표 기입용 빈 양식

Model	P0 EER	P1 EER	Delta EER	TAR@FAR=1%	ROC-AUC	95% CI
Handcrafted + Cosine	-	-	-	-	-	-
1D Siamese CNN	-	-	-	-	-	-
PAPAGEI-S Frozen	-	-	-	-	-	-
PAPAGEI-S Generic SupCon	-	-	-	-	-	-
Cross-Session SupCon	-	-	-	-	-	-
SIM-PPG (Full)	-	-	-	-	-	-

Ablation Variant	EER	TAR@FAR=1%	Score Margin	해석
Full SIM-PPG	-	-	-	-
w/o SQL weighting	-	-	-	-
w/o morphology loss	-	-	-	-
w/o alignment loss	-	-	-	-
generic positive pairs	-	-	-	-
random initialization	-	-	-	-